

Análise Comparativa de Algoritmos de Árvore de Decisão para Predição de Encaminhamentos de Processos Administrativos em Órgãos Públicos.

Deivid Francisco Gonzaga, Anita Maria da Rocha Fernandes

Pós Graduação em Big Data – UNIVALI – Campus Kobrasol – São José – SC

deividfg@gmail.com, anita.fernandes@univali.br

***Abstract.** Under development.*

***Resumo.** Em desenvolvimento.*

1. Introdução

Este trabalho tem como objetivo realizar uma análise comparativa de desempenho, eficácia e acurácia em alguns algoritmos de aprendizagem de máquina na predição de encaminhamentos de processos administrativos em órgãos públicos na tentativa de solucionar o problema de encaminhamentos que não chegam ao setor de destino correto, e posterior utilização do algoritmo escolhido no sistema citado a seguir.

O sistema em questão está implantado há seis anos no órgão do estudo e consiste em um cadastro de processos administrativos físicos e digitais, que automatiza e organiza as rotinas de trabalho do servidor público, auxiliando na eficiência da máquina pública.

Contratação de funcionários, solicitação de férias, pedido de ressarcimento de viagem, pedido de aluguel de imóvel entre outros são exemplos de processos administrativos, podendo estes serem do tipo digital, que são totalmente eletrônicos ou físicos que são encaminhados em papel e eletrônico juntos.

São realizados aproximadamente 1000 (hum mil) encaminhamentos todos os dias, somente no órgão público que está sendo analisado, e estes encaminhamentos por muitas vezes acabam sendo feitos de maneira equivocada, seja por falta de atenção ou mesmo por falta de conhecimento do servidor público.

Quando um processo é recebido pelo setor, o usuário responsável realiza os trâmites e validações necessários para dar prosseguimento, depois decide para qual setor o processo deve ir. Esta decisão é baseada no tipo de processo, em qual setor ele está, qual setor ele foi aberto e outros parâmetros.

O objetivo é utilizar estes parâmetros e indicar ao usuário qual é o setor ideal para o encaminhamento de seu processo, ou seja, encaminhar o processo para o setor que realmente deveria ir, e assim evitar todos os transtornos causados por este tipo de problema, e principalmente as horas a mais que são gastas para resolvê-los, que acabam tornando o órgão menos produtivo e menos eficiente.

Com isso em mente, o que este artigo propõe, é o uso de algoritmos de aprendizagem de máquina do tipo árvore de decisão [Breiman et al 1984] e aprendizagem supervisionada [Caruana e Niculescu-Mizil 2006] com a ferramenta Waikato Environment for Knowledge Analysis (WEKA) [Bouckaert et al 2018].

A escolha pela ferramenta WEKA [Bouckaert et al 2018] se dá, pois o sistema deste estudo está escrito em JAVA, e a ferramenta dispõe de uma biblioteca em JAVA bem estável e com uma ótima documentação, ao qual facilitará a futura implementação da solução no sistema. Ela também é open source sobre a licença GNU (General Public License), podendo assim ser usada sem nenhuma limitação.

Quanto a escolha por árvores de decisão [Breiman et al 1984] se dá pelo fato de conter algoritmos de fácil compreensão e ótimos para resolver problemas de classificação. Eles também podem ser aplicados a qualquer tipo de dado, que é o panorama deste estudo, porém os dados são tratados como categóricos.

E são de aprendizagem supervisionada [Caruana e Niculescu-Mizil 2006] pois os dados históricos de encaminhamentos realizados estão com as classes definidas.

2. Métodos

Todos os métodos e técnicas utilizados neste artigo estão disponíveis na ferramenta WEKA [Bouckaert et al 2018] em sua versão com interface gráfica ao qual é desenvolvida em java, ou seja, multiplataforma.

2.1. Algoritmos

Os algoritmos escolhidos para este artigo são todos os modelos de árvores de decisão que estão disponíveis nativamente na ferramenta WEKA [Bouckaert et al 2018], e que podem ser utilizados com os tipos de dados utilizados neste artigo, são eles:

- **DecisionStump** [Iba & Langley 1992] é um modelo que consiste em gerar uma árvore de decisão de um único nível utilizando entropia. É um algoritmo classificador de aprendizado fraco, que oferece uma baixa taxa de predição, porém como há somente um nível, ele é muito eficiente.
- **HoeffdingTree** [Hulten et al 2001] é um modelo que tem uma característica exclusiva e teoricamente atraente em relação a outros modelos de árvore de decisão, que é o fato de ter garantias sólidas de desempenho. Elas partem do princípio de que, geralmente, uma amostra pequena de dados pode ser suficiente para escolher os atributos de divisão da árvore ideal.
- **C4.5 (no WEKA se chama J48)** [Quinlan 1993] é o modelo mais usado nos dias de hoje, ele também usa de entropia da informação para geração do modelo, onde em cada nó o algoritmo escolhe um atributo que subdivide mais eficientemente o conjunto das amostras em subconjuntos homogêneos e caracterizados por sua classe, sendo que o critério para escolha do atributo para subdivisão é o ganho de informação [Karegowda et al 2010] em cada nó.
- **LMT** [Landwehr et al 2005] [Sumner et al 2005] quer dizer “logistic model trees” ou modelo de árvores logísticas. São árvores de classificação com funções de regressão logística.
- **RandomForest** [Breiman 2001] RandomForest ou floresta aleatória, é um classificador que consiste em uma coleção de classificadores estruturados em árvore. o algoritmo cria várias árvores de decisão e as combina para obter uma predição mais estável e com maior acurácia.
- **RandomTree** [Waikato 1999-2017] é um modelo que constrói uma árvore onde se considera K atributos escolhidos aleatoriamente em cada nó, e não é realizada

a sua poda.

- **REPTree** [Srinivasan 2014] REPTree quer dizer “reduced error pruning tree” ou poda árvore com erro reduzido. É um modelo rápido que constrói uma árvore de decisão [Breiman et al 1984] usando variância ou ganho de informação como critério de divisão, onde a poda a árvore é feita usando poda de erro reduzido.

2.2. Dados

Para o treinamento dos modelos de árvores de decisão [Breiman et al 1984] e a avaliação dos mesmos, foram utilizados os dados de encaminhamentos do ano de 2018.

Quase todos os dados são numéricos, mas devido a natureza dos dados eles são classificados como categóricos, pois não representam valores numéricos.

Os dados estavam em um banco de dados relacional, então foi feita uma consulta em SQL, e posteriormente salvos em um arquivo CSV.

O WEKA [Bouckaert et al 2018] trabalha nativamente com o formato ARFF (Attribute-Relation File Format), porém é possível a importação de arquivos CSV sem muitos problemas. A vantagem da utilização do formato ARFF [Bouckaert et al 2018] neste caso é que os tipos de dados ficam salvos no arquivo, então não precisamos alterar os tipos de dados todas as vezes que é carregado o arquivo na ferramenta.

Então foi carregado o arquivo CSV, alterados os tipos de dados dos atributos, e posteriormente o arquivo foi salvo em formato ARFF [Bouckaert et al 2018] para ser utilizado na ferramenta.

Tabela 1. Dicionário de dados

<i>Atributo</i>	<i>Característica</i>
flTipoProcesso	Indica o tipo de processo, se é protocolo ou processo físico.
nuTramite	Número sequencial do encaminhamento.
cdAssunto	Assunto do qual se trata o processo (intimação, férias, reclamação, concurso, declaração, elogio, indenização, etc.).
cdTipoParecer	Tipo do parecer (despacho, encaminhamento, decisão ou arquivamento).
cdSetorResp	Código do setor responsável pelo processo.
cdSetorAbertura	Código do setor de abertura do processo.
cdSetorAutuacao	Código do setor de autuação do processo.
cdTipoProcesso	Tipo do processo (administrativo, plano geral de autuação, sindicância, disciplinar ou jurídico).
cdUsuario	Código do usuário que realizou o encaminhamento.
cdSetorOrigem	Código do setor onde o processo estava antes de ser encaminhado.
cdSetorDestino	Código do setor onde o processo foi encaminhado (classe).

Os atributos foram selecionados de acordo com o conhecimento da área de negócio. Porém como a quantidade de atributos é proporcional ao tempo de treinamento do modelo, ou seja, quanto mais atributos mais tempo é necessário para treinar o modelo, e como alguns atributos podem ser pouco impactantes ou mesmo irrelevantes para o problema, foi então utilizado o método de seleção de atributos conhecido como ganho de informação (Gain ratio) [Karegowda et al 2010], que faz avaliação do valor

de um atributo medindo a sua taxa de ganho em relação à classe. Com este método, é dada uma nota (mérito) para cada atributo, foram então ranqueados os atributos na seguinte ordem: cdSetorOrigem, cdSetorAbertura, cdSetorResp, cdUsuario, cdAssunto, cdSetorAutuacao, cdTipoParecer, flTipoProcesso, nuTramite, cdTipoProcesso.

Para avaliar quantos atributos deveriam ser retirados para a construção dos modelos, foi removido cada atributo na ordem inversa, gerando os modelos de cada algoritmo, e avaliando os resultados para que não perdessem sua eficácia e melhorassem a sua eficiência. Assim, foi definido que seriam removidos metade dos atributos.

Tabela 2. Comparação de algoritmos para seleção de atributos.

<i>Algoritmo</i>	<i>Tempo de criação do modelo (em segundos)</i>		<i>Instâncias classificadas corretamente (%)</i>	
	<i>10 atributos</i>	<i>5 atributos</i>	<i>10 atributos</i>	<i>5 atributos</i>
DecisionStump	0,03	0	24,1454	24,6392
HoeffdingTree	1,67	0,99	46,56	44,4601
J48	1,34	0,53	51,7743	50,2116
LMT	-	-	-	-
RandomForest	-	-	-	-
RandomTree	1,84	1,02	42,2084	47,5583
REPTree	1,52	0,72	44,4547	46,3158

Conforme a tabela 2 acima, podemos ver que os tempos de criação dos modelos foram reduzidos significativamente, e sua eficácia em alguns casos até aumentou. Também percebemos que os algoritmos LMT e RandomForest não obtiveram resultados, pois a memória do computador utilizado não suportou estes modelos, mesmo com a quantidade de atributos reduzida.

3. Resultados

Em desenvolvimento.

4. Conclusões

Em desenvolvimento.

5. Referências

- Breiman, L., Friedman, J.H., Olshen, R.A., & Stone, C.J. (1984) "Classification and regression trees" Wadsworth International Group, Belmont, CA.
- Caruana, R., & Niculescu-Mizil, A. (2006) "An empirical comparison of supervised learning algorithms", In: Proceedings of the twenty-third international conference on machine learning (ICML'06), Edited by William Cohen & Andrew Moore, ACM New York, NY, USA, p. 161-168.
- Karegowda, A.G., Manjunath, A.S., & Jayaram, M.A. (2010) "Comparative study of attribute selection using gain ratio and correlation based feature selection", In: International Journal of Information Technology and Knowledge Management

(IJITKM), Volume 2, No. 2, p. 271-277.

Bouckaert, R. R., Frank, E., Hall M., Kirkby R., Reutemann P., Seewald, A., Scuse D. (2018) "WEKA Manual for Version 3-8-3", In: The University of Waikato, September.

Iba, W. & Langley, P. (1992) "Induction of One – Level Decision Trees" In: Proceedings of the Ninth International Conference on Machine Learning.

Quinlan, J. R. (1993) "C4.5: Programs for machine learning", Morgan Kaufmann Publishers Inc, San Mateo, CA, USA.

Hulten G., Spencer L., Domingos P. (2001) "Mining time-changing data streams." In: ACM SIGKDD Intl. Conf. on Knowledge Discovery and Data Mining, p. 97-106.

The University of Waikato, (1999-2017) "WEKA Documentation", <http://weka.sourceforge.net/doc.dev/>

Srinivasan, B., Mekala, P. (2014) "Mining Social Networking Data for Classification Using REPTree", International Journal of Advance Research in Computer Science and Management Studies, Volume 2, p. 155-160.

Landwehr, N., Hall, M., Frank, E. (2005) "Logistic Model Trees. Machine Learning", p. 161-205.

Sumner, M., Frank, E., Hall, M. (2005) "Speeding up Logistic Model Tree Induction", In: 9th European Conference on Principles and Practice of Knowledge Discovery in Databases, p. 675-683.

Breiman, L. (2001) "Random Forests. Machine Learning." p5-32.